面向 Open RAN 的可信 AI 分析报告

目标读者：AI 研究专用版

生成时间:
[cci_a1sd_binary] xgboost — accuracy=1.000
个人研究项目，与任何雇主无关。

目录

- 结论摘要
- 数据集与模型
- 基础性能
- 可解释性
- 鲁棒性
- 公平性
- 隐私性
- O-RAN 控制台快照
- Agent 可信评测
- 方法论与有效性边界

结论摘要

方法学摘要：以下所有数字均来自同一次 TrustPipeline 运行（留出测试集，随机种子 42），并按需叠加 0 个用例的 trace 级 trustagent 评测。

关键读数

指标	数值
准确率	0.9996
F1(宏)	0.9996
Roc auc	0.9998
PGD 攻击成功率	0.32
成员推断 AUC	0.4946

所报告的是无置信区间的点估计。固定随机种子是为了可复现，并不代表结果可跨数据集外推。

数据集与模型

数据集

指标	数值
数据集	cci_a1sd_binary
任务	binary
样本数	24000
特征数	10
类别	Normal, Dos
分组属性	policy_type_id, load_label, operation, policy_name
类别数量	Normal=12000; Dos=12000

数据集内容：A1 接口流量的 Normal 与 DoS 二分类。

模型配置

指标	数值
模型	xgboost
任务	binary
超参	n_estimators=200; max_depth=6; learning_rate=0.1; subsample=0.9; colsample_bytree=0.9; random_state=42
耗时(秒)	5.95

特征列表

指标	数值
特征	real_interval, inter_arrival_mean, inter_arrival_std, inter_arrival_cv, response_time_mean, response_time_std ...
数据元信息	source=CCI-A1SD; dos_variant=dos2; classes=normal, dos; per_class_cap=20000; imputed_readings=0; policy_names=20008=Traffic Steering; 20009=QoS Management; 20010=Resource Allocation; 20011=Slice SLA; 20012=Energy Saving; 20013=Load Balancing

基础性能

留出测试集上的核心指标。

指标	数值
准确率	0.9996
F1(宏)	0.9996
Roc auc	0.9998

图表与各面板显示的内容出自同一次运行。

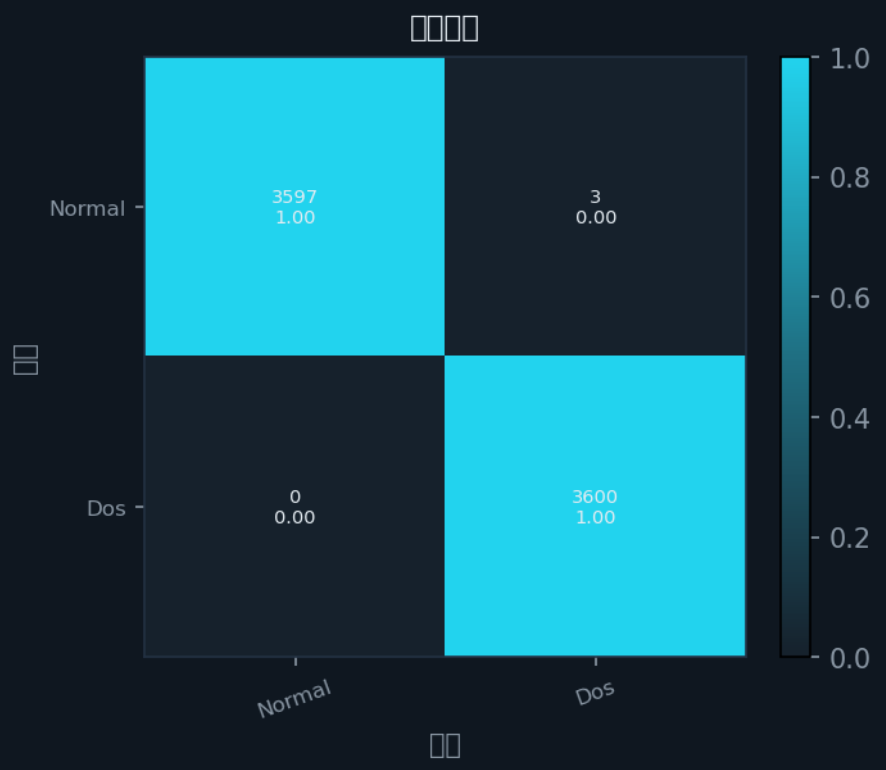


类别分布

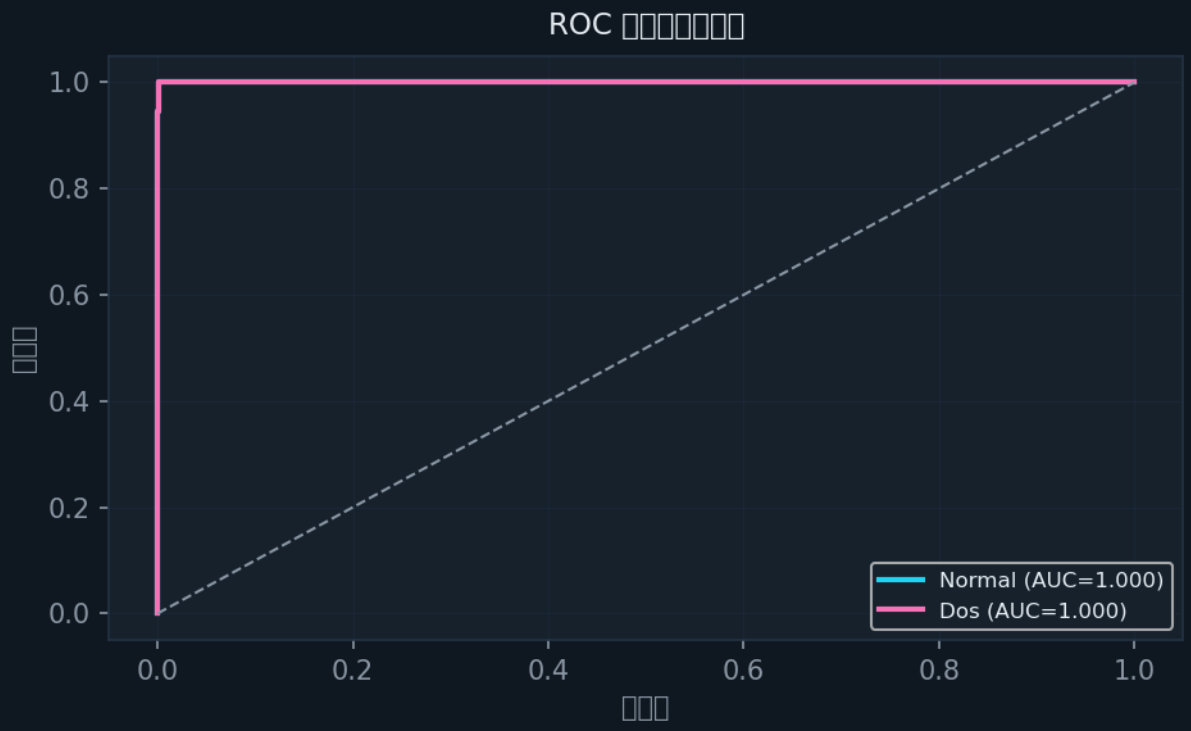
cci_a1sd — □□□□



特征直方图



混淆矩阵



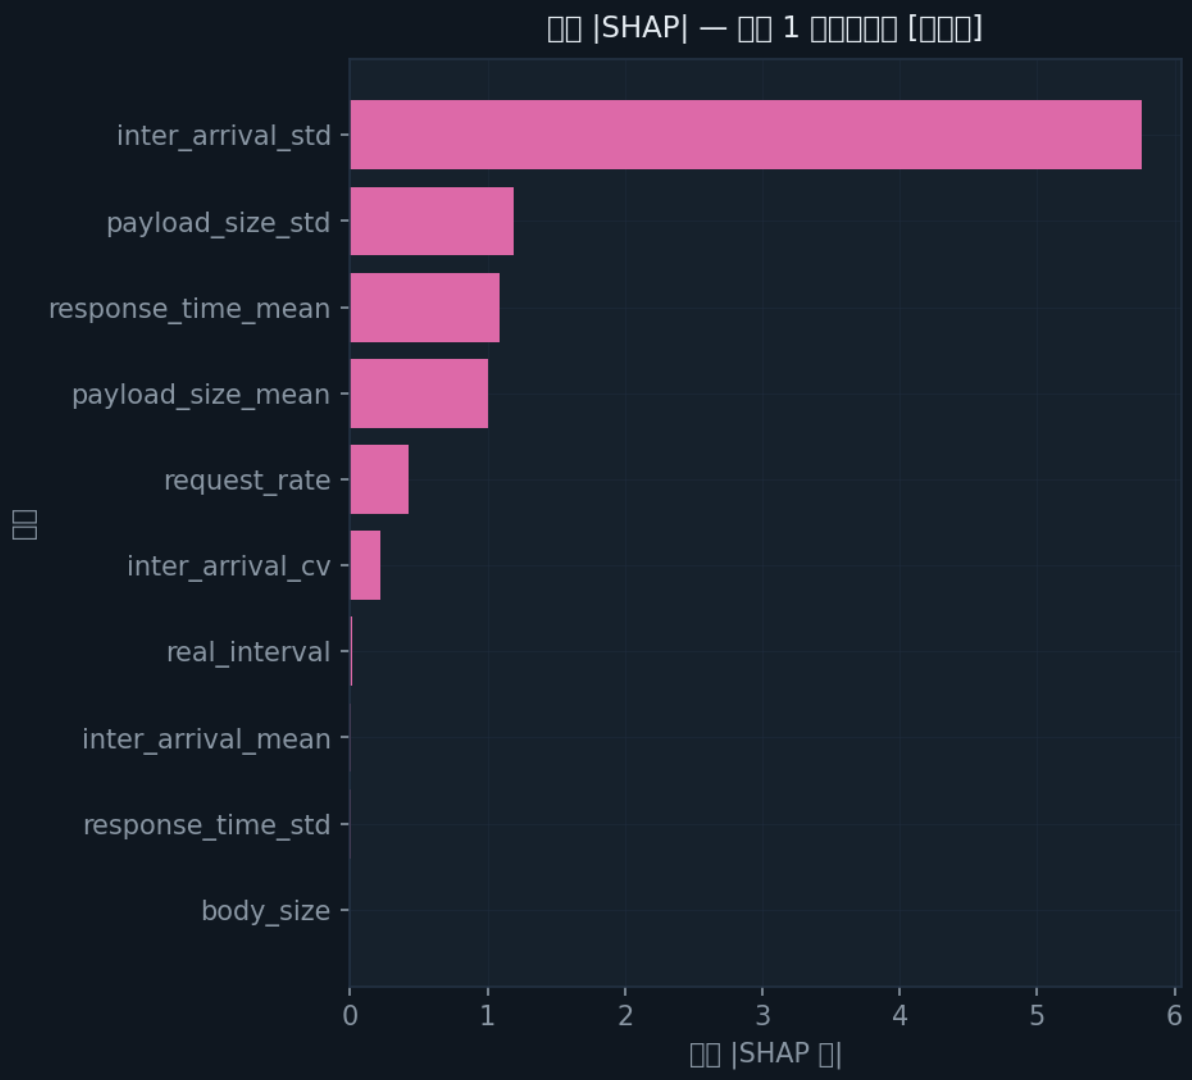
ROC 曲线

可解释性

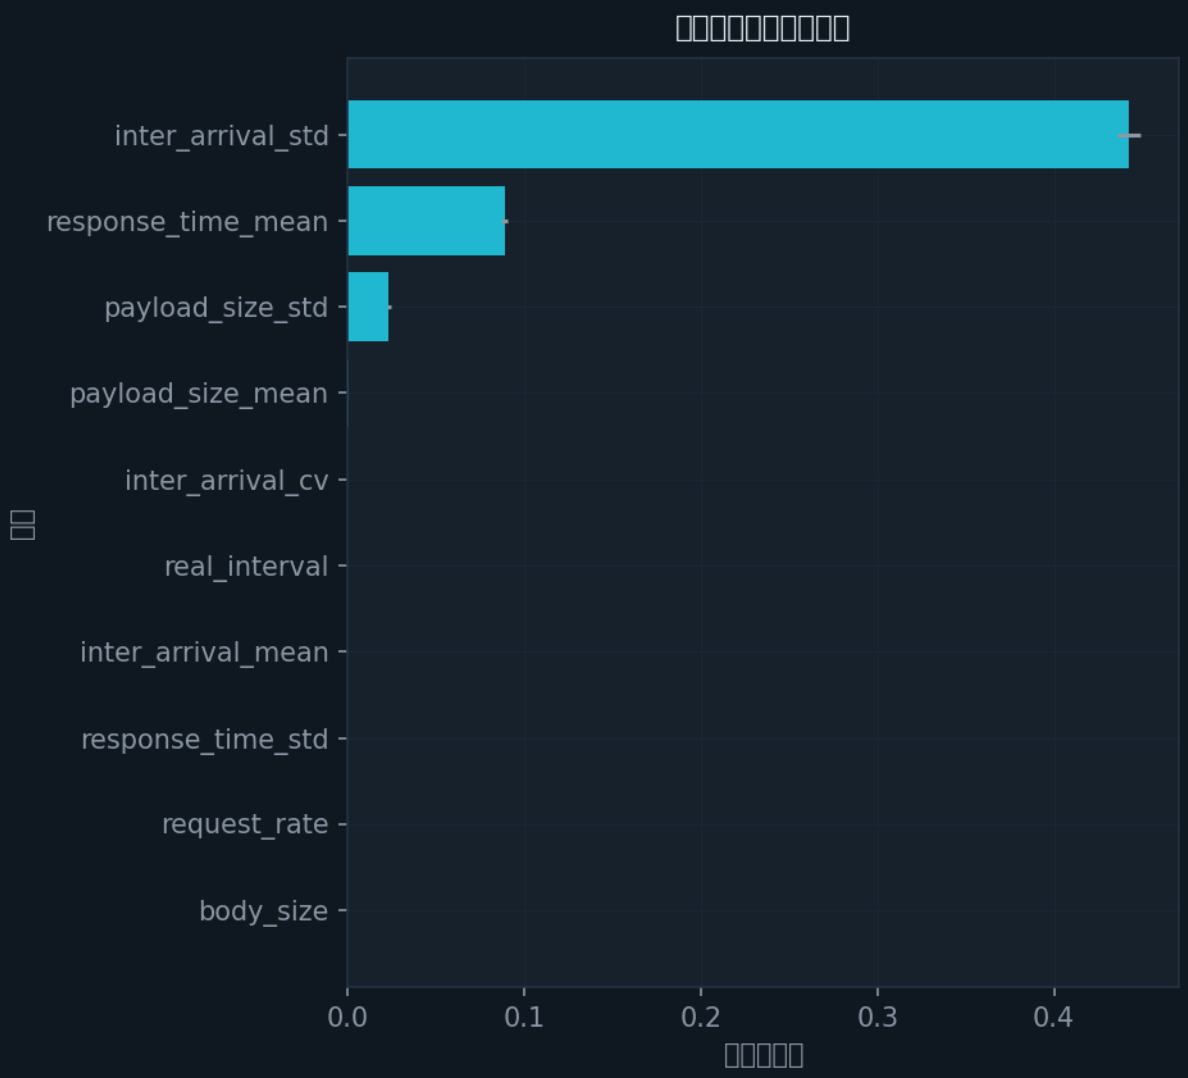
排列重要性、KernelSHAP 风格归因、LIME 风格局部代理以及 PDP/ICE 曲线，均在测试集上计算。

指标	数值
Top 特征	inter_arrival_std, response_time_mean, payload_size_std, payload_size_mean, inter_arrival_cv
目标	类别 1 的对数几率

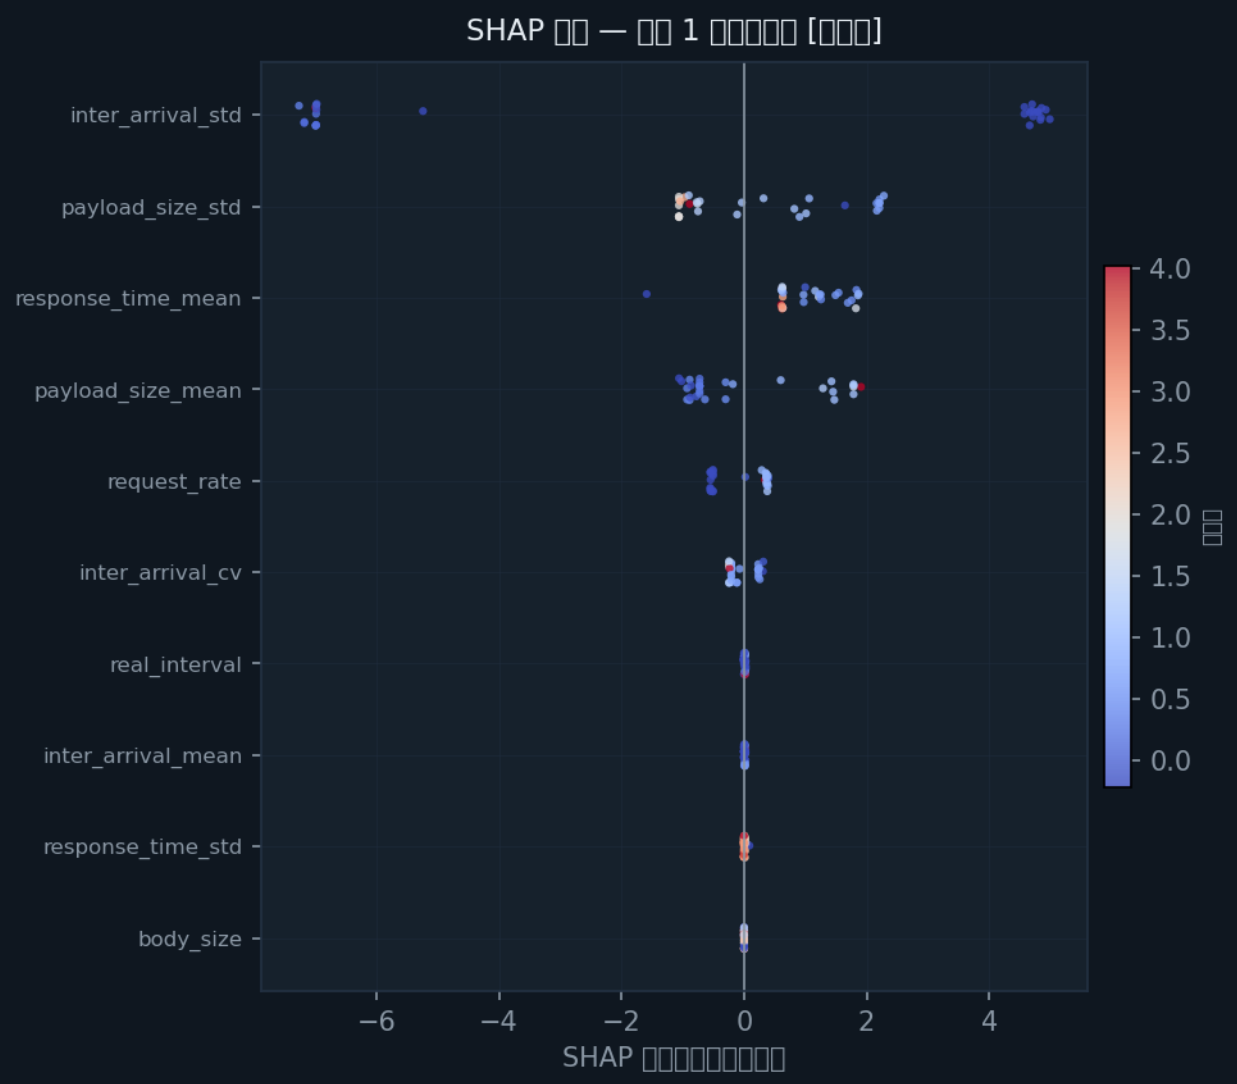
指标	数值
SHAP Top	inter_arrival_std, payload_size_std, response_time_mean, payload_size_mean, request_rate
方法	置换重要性 + 精确 TreeSHAP（库原生 pred_contribs）+ LIME 式局部代理 + PDP/ICE 曲线
归因估计器	精确解
效率残差(最大)	6.284e-06



SHAP 条形


□□□□□□□□□□□□
inter_arrival_std
response_time_mean
payload_size_std
payload_size_mean
inter_arrival_cv
real_interval
inter_arrival_mean
response_time_std
request_rate
body_size
□□
0.0
0.1
0.2
0.3
0.4
□□□□□□

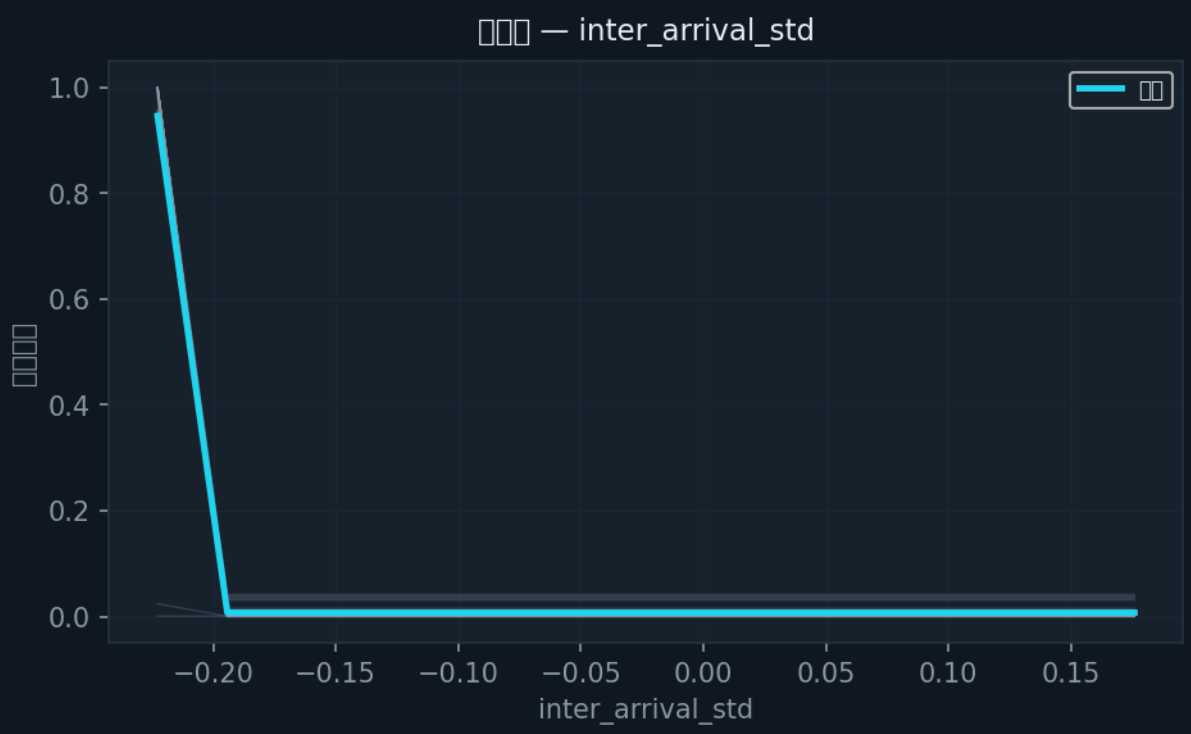
置换重要性


SHAP □□ — □□ 1 □□□□□□ [□□□]
inter_arrival_std
payload_size_std
response_time_mean
payload_size_mean
request_rate
inter_arrival_cv
real_interval
inter_arrival_mean
response_time_std
body_size
−6
−4
−2
0
2
4
SHAP □□□□□□□□□□
4.0
3.5
3.0
2.5
2.0
1.5
1.0
0.5
0.0
□□□

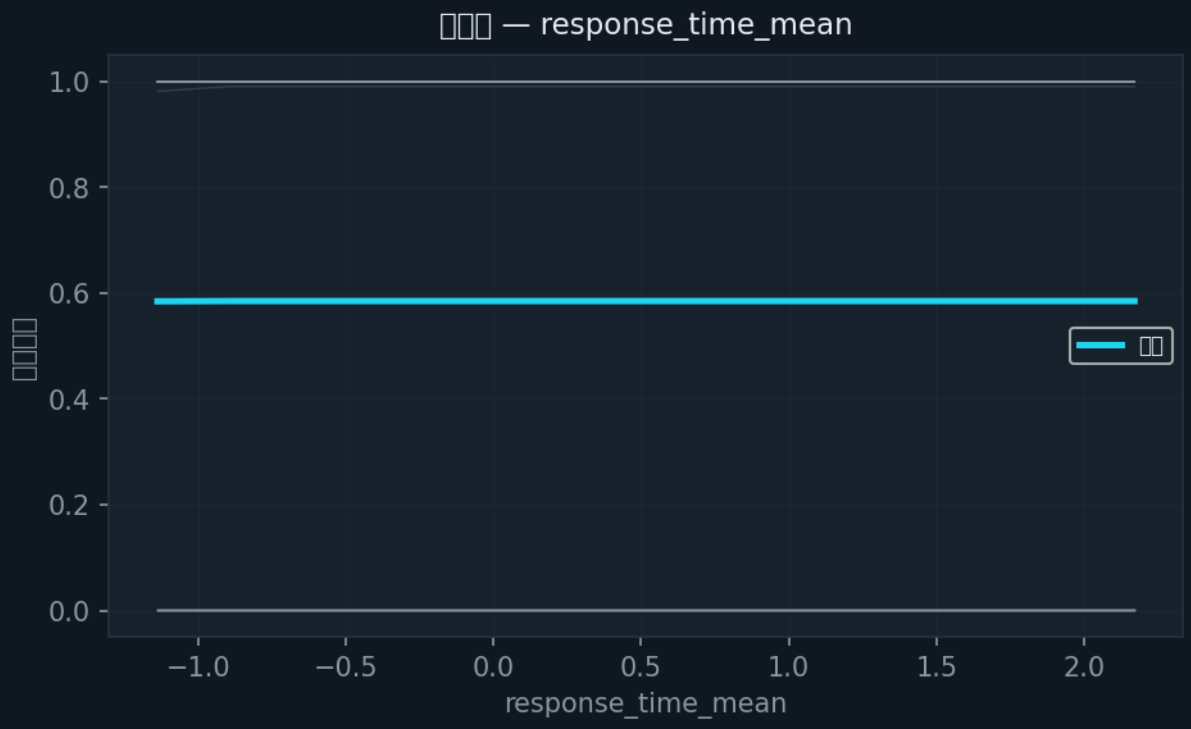
SHAP 蜂群


□□□□□□□□□□□=1.000□□□=0.517□
body_size
inter_arrival_cv
real_interval
response_time_mean
inter_arrival_mean
response_time_std
payload_size_mean
payload_size_std
request_rate
inter_arrival_std
□□
0.0
0.2
0.4
0.6
0.8
□□□□□□□

局部解释



PDP · 到达间隔波动



PDP · 平均响应时间

置换重要性

feature	permutation	permutation_std	native
inter_arrival_std	0.442	0.006529	0.5206
response_time_mean	0.08872	0.001627	0.1625
payload_size_std	0.02316	0.0012	0.0201
payload_size_mean	0.0004514	0.000248	0.007406
inter_arrival_cv	6.944e-05	6.944e-05	0.001617

feature	permutation	permutation_std	native
real_interval	0	0	0.00152
inter_arrival_mean	0	0	0.001576
response_time_std	0	0	0.001531
request_rate	0	0	0.2832
body_size	0	0	0

SHAP 均值

feature	mean_abs_shap
inter_arrival_std	5.761
payload_size_std	1.187
response_time_mean	1.087
payload_size_mean	1.001
request_rate	0.4253
inter_arrival_cv	0.2207
real_interval	0.01131
inter_arrival_mean	0.01047
response_time_std	0.009575
body_size	0

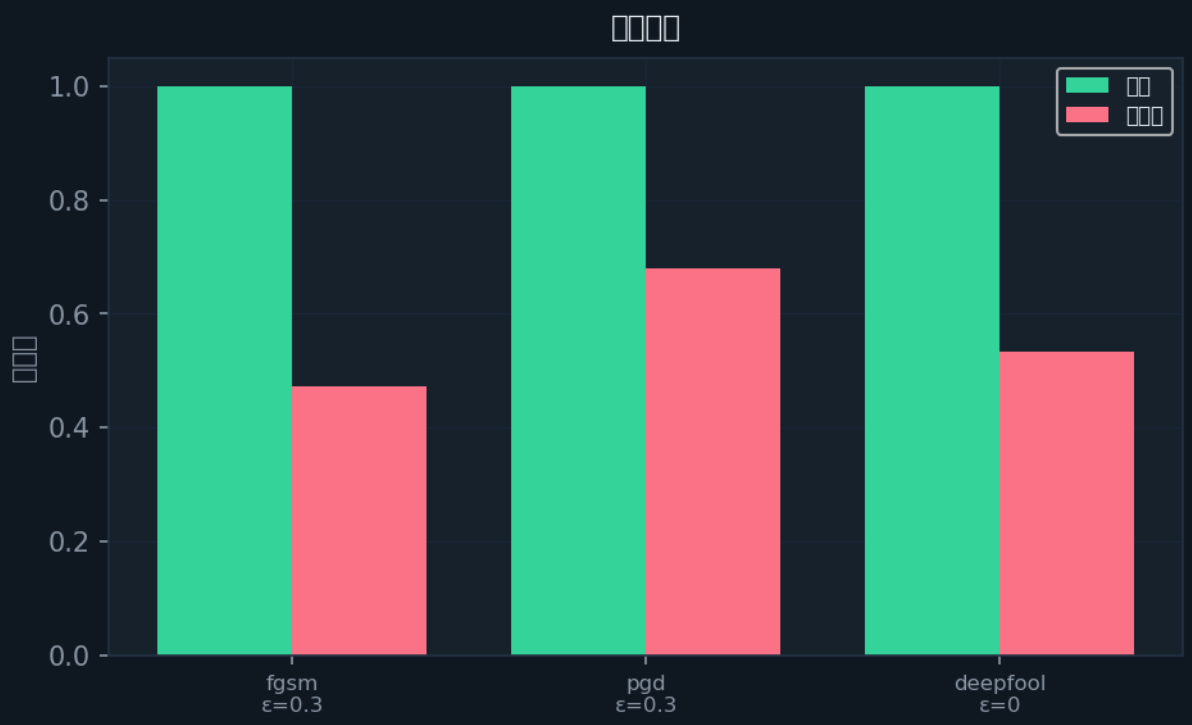
局部解释

feature	contribution
inter_arrival_std	0.8122
request_rate	-0.07009
payload_size_std	0.06142
payload_size_mean	0.04718
response_time_std	-0.02905
inter_arrival_mean	-0.02265
response_time_mean	-0.01553
real_interval	-0.01399
inter_arrival_cv	0.01183
body_size	0.008597

鲁棒性

基于代理梯度的 FGSM / PGD / DeepFool 攻击、ε 扫描下的鲁棒性曲线，以及作为防御基线的对抗训练。

指标	数值
干净准确率	1
FGSM 鲁棒准确率	0.4733
PGD 鲁棒准确率	0.68
DeepFool 鲁棒准确率	0.5333
PGD 攻击成功率	0.32
对抗训练鲁棒准确率@0.6	0.9667



攻击对比



FGSM 鲁棒性



PGD 鲁棒性



对抗训练

攻击对比

attack	eps	clean_accuracy	robust_accuracy	attack_success_rate	mean_perturbation
fgsm	0.3	1	0.4733	0.5267	0.3
pgd	0.3	1	0.68	0.32	0.3
deepfool	0	1	0.5333	0.4667	53.7

FGSM 鲁棒性

epsilon	accuracy
0	1
0.1	0.4733
0.3	0.4733
0.6	0.4733
1	0.4733

PGD 鲁棒性

epsilon	accuracy
0	1
0.1	0.7533
0.3	0.68
0.6	0.6333
1	0.5933

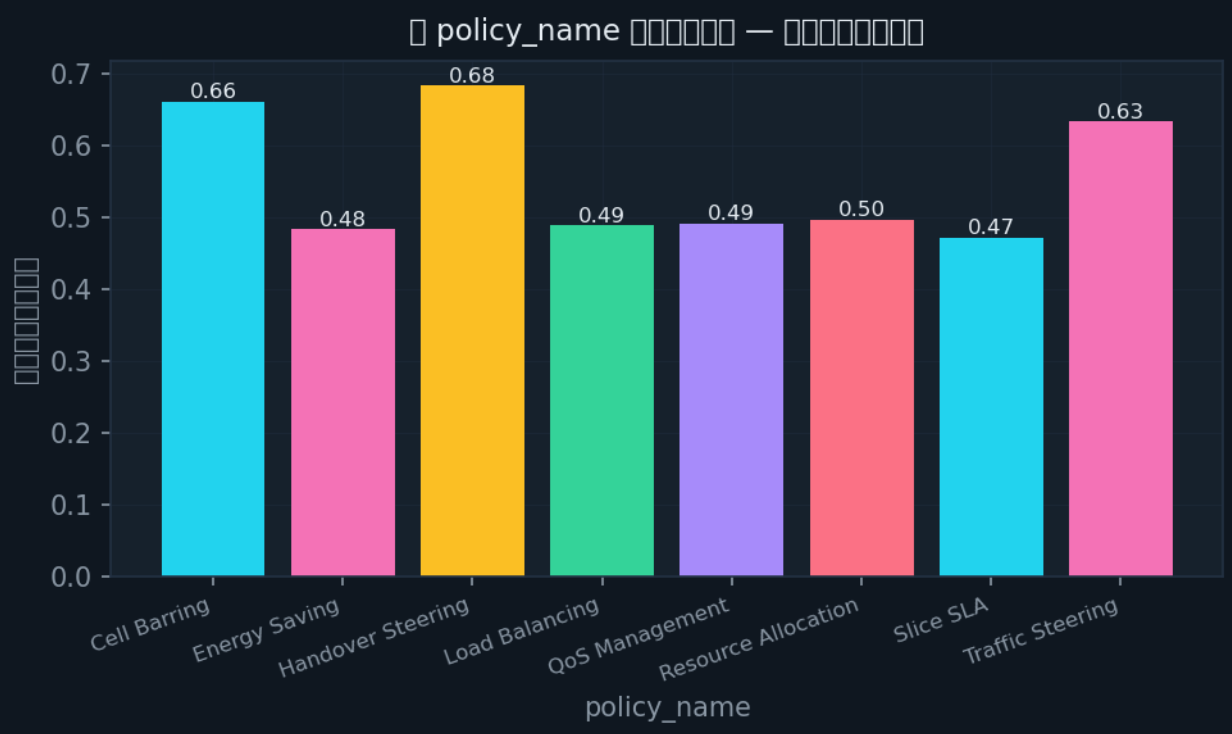
对抗训练

epsilon	accuracy
0	1
0.1	0.98
0.3	0.9733
0.6	0.9667
1	0.96

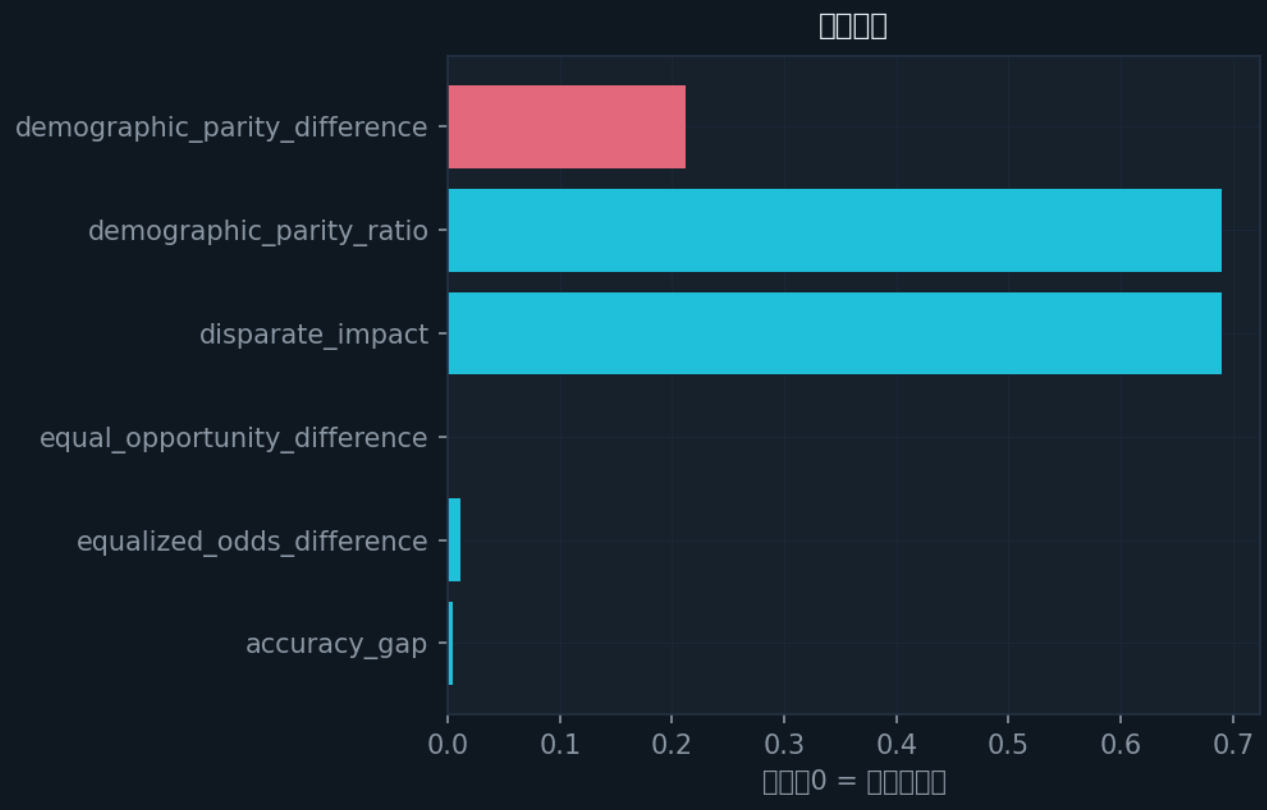
公平性

各分组的选择率与错误率、人口平衡、差异影响以及均等化几率差异，共覆盖 8 个分组。

指标	数值
分组属性	policy_name
组数	8
人口平价差	0.212
人口平价比	0.6897
差异影响	0.6897
机会均等差	0
均等化几率差	0.0116
准确率差	0.0043



分组公平



公平指标

分组指标

group	n	selection_rate	tpr	fpr	fnr	accuracy	precision	positives
Cell Barring	186	0.6613	1	0	0	1	1	123

group	n	selection_rate	tpr	fpr	fnr	accuracy	precision	positives
Energy Saving	1330	0.4835	1	0.001453	0	0.9992	0.9984	642
Handover Steering	180	0.6833	1	0	0	1	1	123
Load Balancing	1312	0.4886	1	0.001488	0	0.9992	0.9984	640
QoS Management	1287	0.4918	1	0	0	1	1	633
Resource Allocation	1332	0.4962	1	0	0	1	1	661
Slice SLA	1341	0.4713	1	0	0	1	1	632
Traffic Steering	232	0.6336	1	0.01163	0	0.9957	0.9932	146

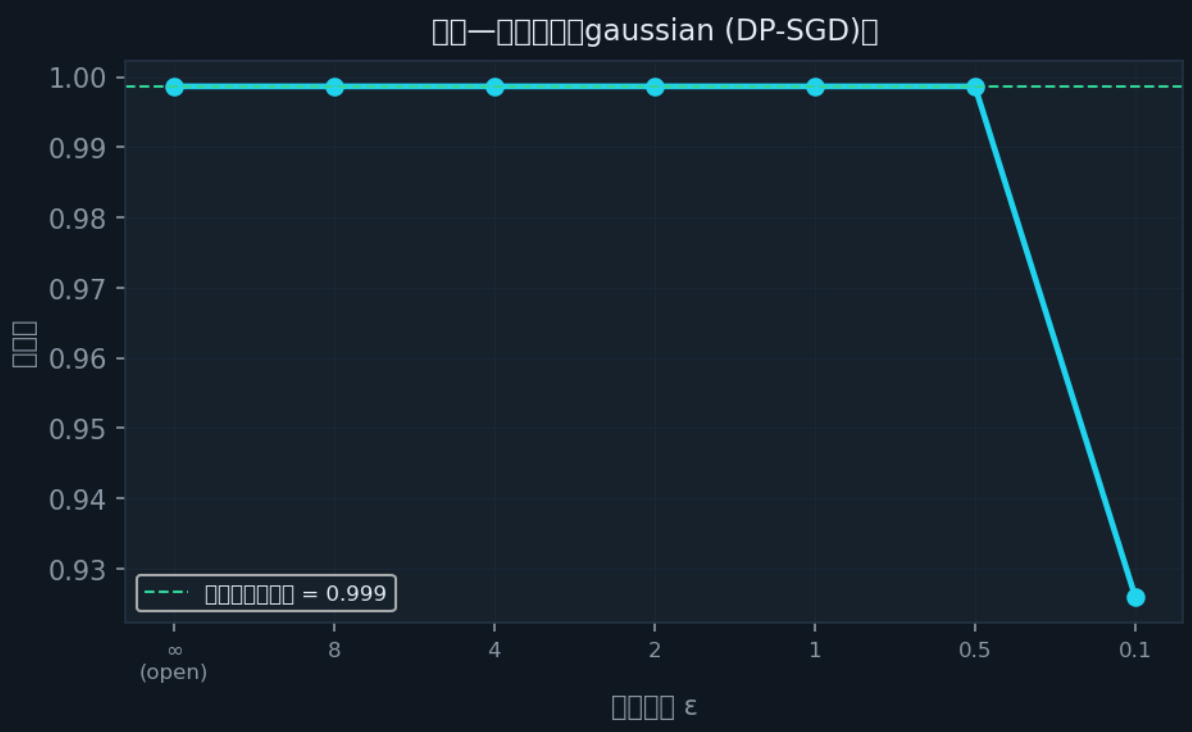
差异指标

metric	value
人口平价差	0.212
人口平价比	0.6897
差异影响	0.6897
机会均等差	0
均等化几率差	0.01163
准确率差	0.00431

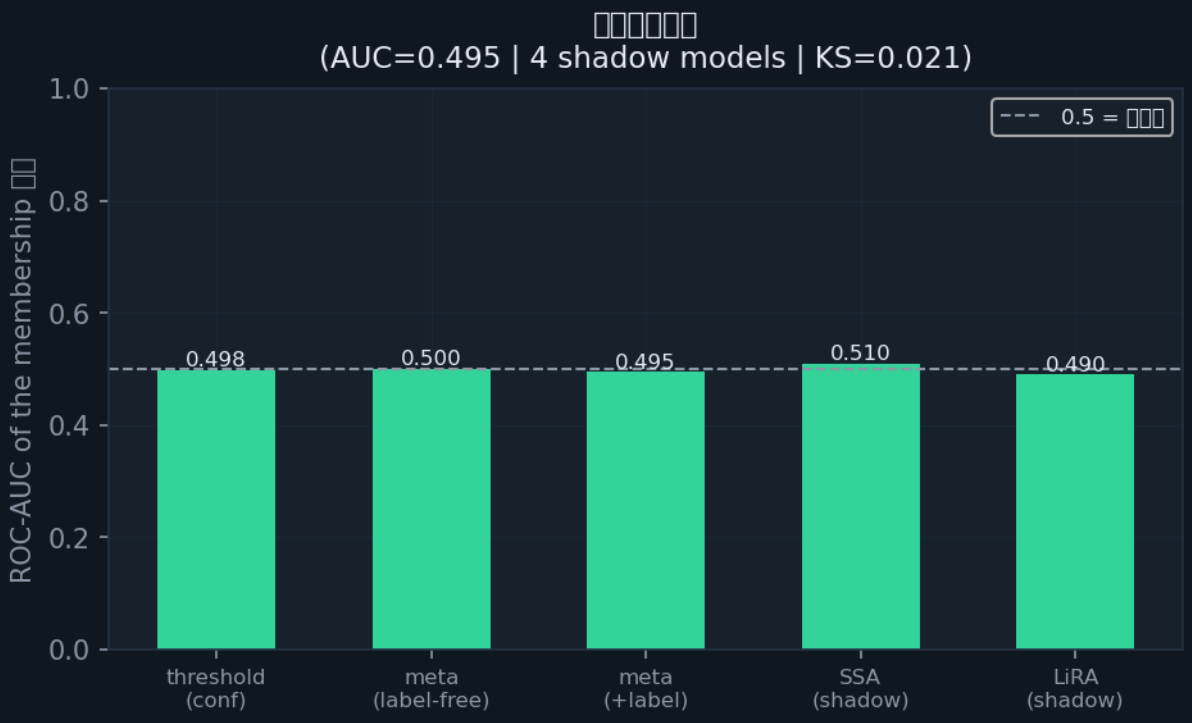
隐私性

ε 扫描下的 DP-SGD（逐样本梯度 + 矩估计记账）、跨 — 个客户端的 FedAvg，以及成员推断攻击组（置信度阈值攻击、含标签特征的元模型攻击、影子模型 SSA 与 LiRA）。

指标	数值
DP 机制	高斯机制（DP-SGD）
无隐私效用	0.9987
效用@ε=1	0.9987
效用@ε=0.1	0.926
成员推断 AUC	0.4946
影子攻击 AUC	0.51
LiRA AUC	0.4904
无标签特征 AUC	0.5
成员/非成员 KS	0.02133
1% 误报命中率	0
影子模型数	4



DP 曲线



成员推断

DP 曲线

epsilon	utility
∞	0.9987
8	0.9987
4	0.9987
2	0.9987
1	0.9987

epsilon	utility
0.5	0.9987
0.1	0.926

成员推断

metric	value
攻击 AUC	0.4946
攻击准确率	0.5025
阈值攻击 AUC	0.4978
元模型 AUC（无标签特征）	0.5
元模型 AUC（含标签特征）	0.4946
SSA 影子攻击 AUC	0.51
LiRA 影子攻击 AUC	0.4904
SSA 影子攻击准确率	0.6662
KS 统计量	0.02133
1% 误报率下的命中率	0
置信度差	0.0001561
泛化间隙	0.0006667
近重复率	0
影子模型数	4

O-RAN 控制台快照

本次未采集到控制台会话状态。

Agent 可信评测

尚未运行 Agent 评测：在 Agent 评测面板运行一次即可填充本节。

方法论与有效性边界

可复现性

```
python -m trustoran --dataset cci_a1sd_binary --model xgboost --pillars all --quick
python -m trustagent --quick
```

指标定义

干净准确率	未施加扰动时的准确率（基线）。
FGSM 鲁棒准确率	给定 ε 下单步 FGSM 攻击后的准确率。
PGD 鲁棒准确率	ε 球内 10 步 PGD 优化后的准确率。
DeepFool 鲁棒准确率	最小扰动 DeepFool 攻击后的准确率。
PGD 攻击成功率	被 PGD 改变真实标签的样本比例。
对抗训练鲁棒准确率@0.6	在对抗样本上重训后的同结构模型准确率。
人口平价差	各组选择率的最大最小差。
差异影响	最小/最大选择率之比，即 4/5 规则所用指标。
均等化几率差	各组之间 TPR/FPR 的最大差距。

干净准确率	未施加扰动时的准确率（基线）。
准确率差	最优组与最差组准确率之差。
无隐私效用	不加隐私约束的基线效用：分类任务为准确率，回归任务为 R^2。
效用@ε=1	隐私预算 ε=1 时的效用：分类任务为准确率，回归任务为 R^2。
成员推断 AUC	元模型成员推断攻击 AUC（判别特征含真实标签侧），0.5 表示无泄露信号；阈值攻击、影子模型 SSA 与似然比 LiRA 的读数并列给出。

有效性边界

- 数据均为公开研究数据集，非生产网 RAN 遥测数据。
- 攻击采用可微代理梯度，鲁棒性数字刻画的是该类攻击族的效果，不代表任意攻击者。
- 隐私记账沿用本地 DP-SGD 循环中的矩估计方法，未对最终模型给出形式化的 (ε,δ) 证明。
- 公平性分组是在 DATASET_PROFILES 中按数据集预先确定的建模选择，非数据本身的属性。
- Agent 运行环境是带 ACL、预算与确认门的沙箱，未触及任何真实系统或网元。
- Mock 模式下的 Agent 数字只验证评测框架本身，不构成对任何真实模型的测量。
- 规范性表述请直接查阅 O-RAN Alliance 官方规范。

本模块为个人研究项目，将可信 AI 方法论扩展至 Agent 评测，与任何雇主无关。O-RAN 场景与规范摘要均为公开资料的本人转述。