面向 Open RAN 的可信 AI 分析报告

目标读者：非专业人士版

生成时间:

在数据集 cci_a1sd_binary 上以模型XGBoost运行，准确率 100.0%

个人研究项目，与任何雇主无关。

目录

- 一页结论：有效性与可信度
- 测试数据与模型说明
- 模型答对的比例
- 模型的判定依据（可解释性）
- 输入被篡改时的表现（鲁棒性）
- 分组间的一致性（公平性）
- 单条数据的泄露风险（隐私性）
- 模拟控制室的运行结果
- 智能体评测得分
- 数字来源与方法

一页结论：有效性与可信度

本页以平实表述给出这类系统最常见的几项结论。其中每个数字均为本报告后文所述那次运行的实测值，没有另行估算。

系统有效性

仅在训练阶段未见过的数据上测试，答对比例为 100.0%。这一项达标。

按类别均衡计算（避免少数类别被多数类别掩盖）后的得分为 100.0%。这一项无需处置。

判定依据是否可核查

模型做出判定时最依赖的测量项：到达间隔波动：该值越小，模型输出“DoS 攻击”的倾向越强；平均响应时间：该值越小，模型输出“DoS 攻击”的倾向越强；载荷大小波动：该值越小，模型输出“DoS 攻击”的倾向越强；平均载荷大小：该值越大，模型输出“DoS 攻击”的倾向越强；到达间隔变异系数：该值越小，模型输出“DoS 攻击”的倾向越强。

这些均非黑箱内部量：影响结果的每一项都是运维可查询、可讨论的测量项。

抗扰动能力

未施加篡改时模型准确率为 100.0%。随后按攻击者的方式对输入施加篡改，共三种强度递增的方法：单步小幅扰动：47.3%；多步反复试探的攻击：68.0%；能奏效的最小改动：53.3%。

影响最大的一种攻击使准确率由 100.0% 降至 47.3%，降幅 52.7 个百分点；该代价在实验设计阶段已量化。这一项不达标，需处理。

分组间一致性

样本按策略名称分为 8 组。考察的是各组的准确率与告警倾向是否一致，是否存在某一组的判定更宽松或更严格。

单条数据泄露风险

由外部人员自行训练的 4 个影子模型重跑同一测试，群体攻击得分 0.51，似然比攻击得分 0.4904，读数不依赖单一攻击设计。

本报告最后一节列出这些数字未证明的部分，引用前应先阅读。

测试数据与模型说明

数据集内容：A1 接口流量的 Normal 与 DoS 二分类。

共 24000 条样本，每条 10 项测量，均取自同一次事件。

模型的任务是把每个样本归入 2 类之一：正常、DoS 攻击。

所用模型为XGBoost，即带正则化的梯度提升树（XGBoost）。模型训练与全部检查共耗时 5.95 秒。

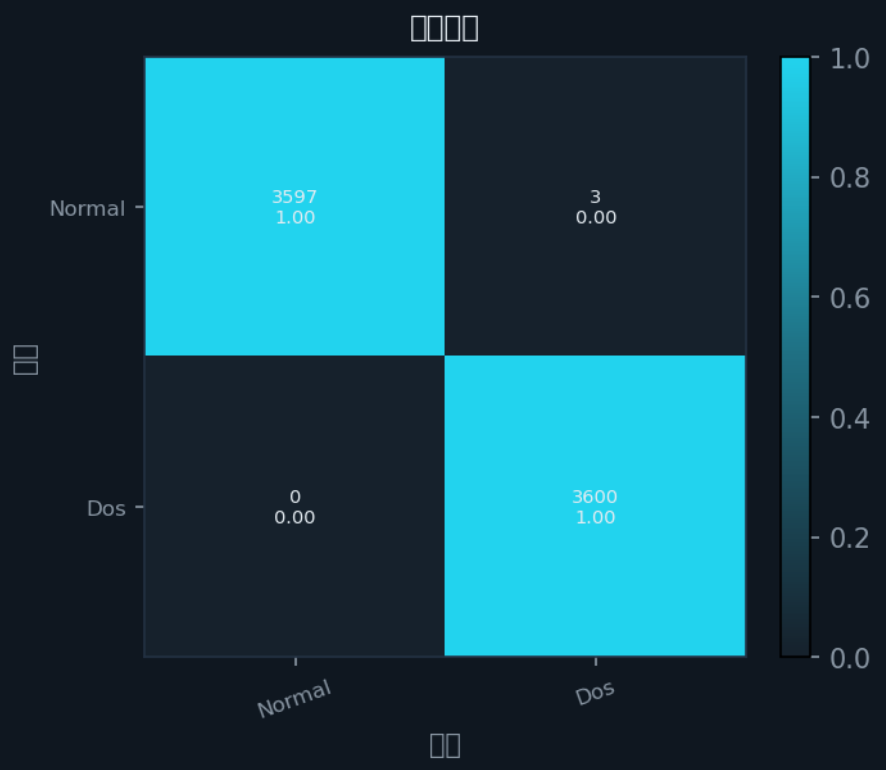
测量项清单

实际到达间隔、平均到达间隔、到达间隔波动、到达间隔变异系数、平均响应时间、响应时间波动、请求速率、平均载荷大小、载荷大小波动、请求体大小。

模型答对的比例

仅在训练阶段未见过的数据上测试，答对比例为 100.0%。这一项达标。

按类别均衡计算（避免少数类别被多数类别掩盖）后的得分为 100.0%。这一项无需处置。



哪几类容易被混淆

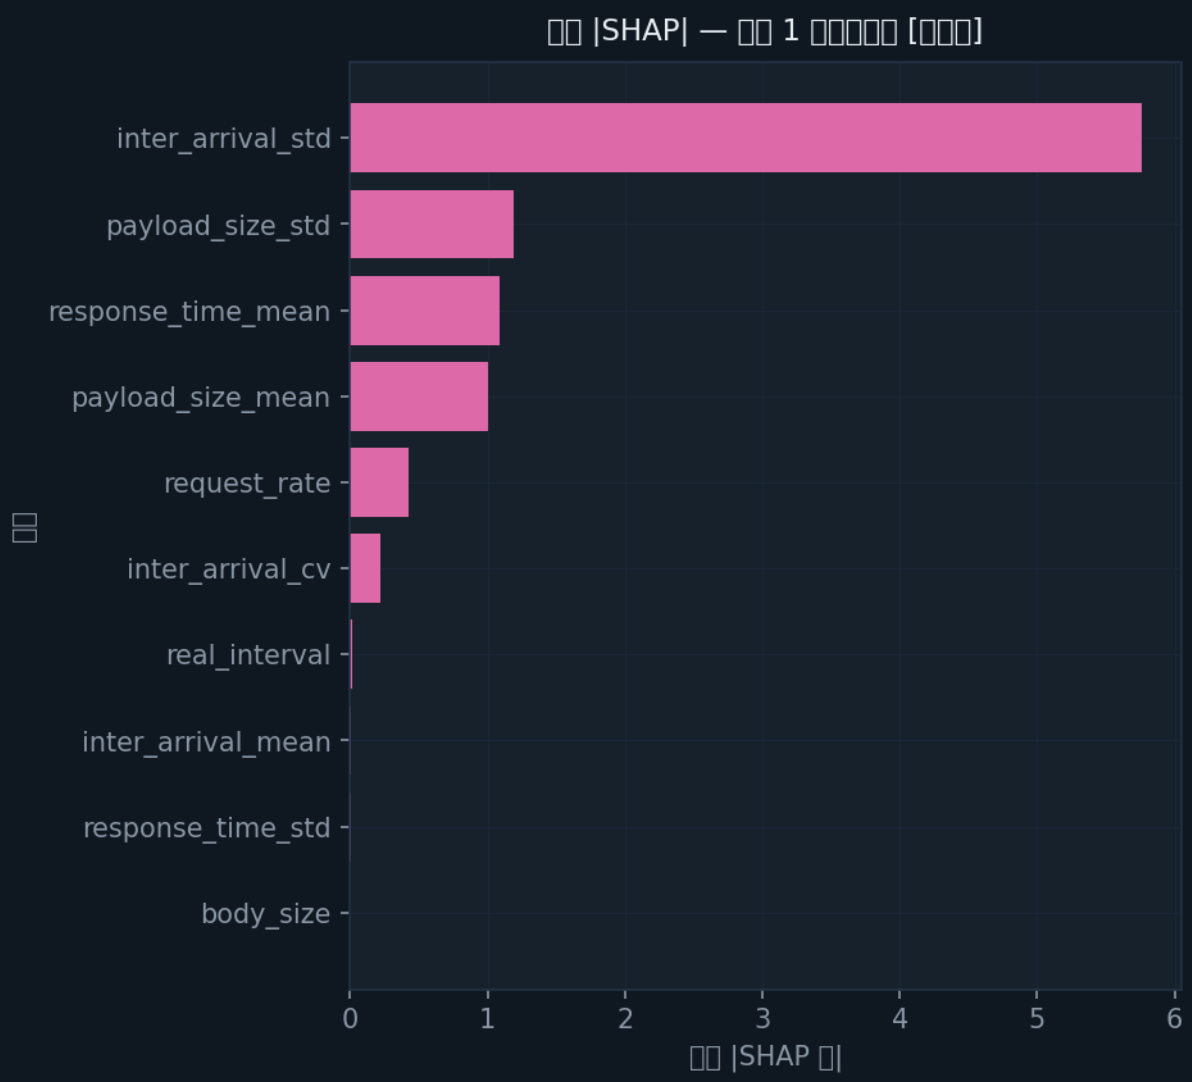
模型的判定依据（可解释性）

本节回答一个问题：模型判定时依据哪些测量量，使结果可被核查与讨论。

模型做出判定时最依赖的测量项：到达间隔波动：该值越小，模型输出“DoS 攻击”的倾向越强；平均响应时间：该值越小，模型输出“DoS 攻击”的倾向越强；载荷大小波动：该值越小，模型输出“DoS 攻击”的倾向越强；平均载荷大小：该值越大，模型输出“DoS 攻击”的倾向越强；到达间隔变异系数：该值越小，模型输出“DoS 攻击”的倾向越强。

这些均非黑箱内部量：影响结果的每一项都是运维可查询、可讨论的测量项。

单个案例拆解：促使本条判为“DoS 攻击”的因素：到达间隔波动（+0.812）、载荷大小波动（+0.061）；抑制该判定的因素：请求速率（-0.070）、响应时间波动（-0.029）。



每项测量对结果的影响幅度

输入被篡改时的表现（鲁棒性）

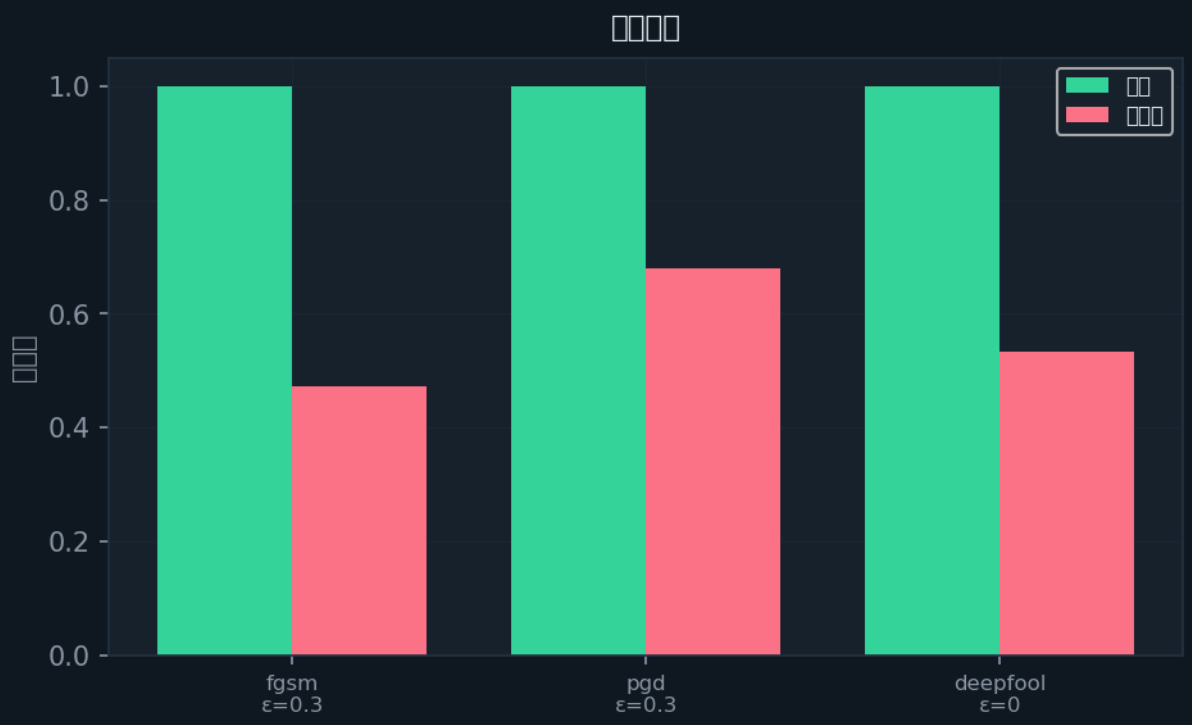
本节对输入施加篡改，用于观察输出在多强的扰动下开始出错。

未施加篡改时模型准确率为 100.0%。随后按攻击者的方式对输入施加篡改，共三种强度递增的方法：单步小幅扰动：47.3%；多步反复试探的攻击：68.0%；能奏效的最小改动：53.3%。

影响最大的一种攻击使准确率由 100.0% 降至 47.3%，降幅 52.7 个百分点；该代价在实验设计阶段已量化。这一项不达标，需处理。

逐条统计：多步试探攻击使模型在 32.0% 的样本上改变了判定。这是短板：修复前不应作为决策依据。

缓解措施：用篡改样本对同一模型重新训练，准确率可回升至 96.7%，同一攻击下比未做对抗训练的模型高 49.3 个百分点。



三种篡改方式下的准确率

分组间的一致性（公平性）

本节检查不同站点、终端或平台分组之间，是否存在系统性的表现差异。

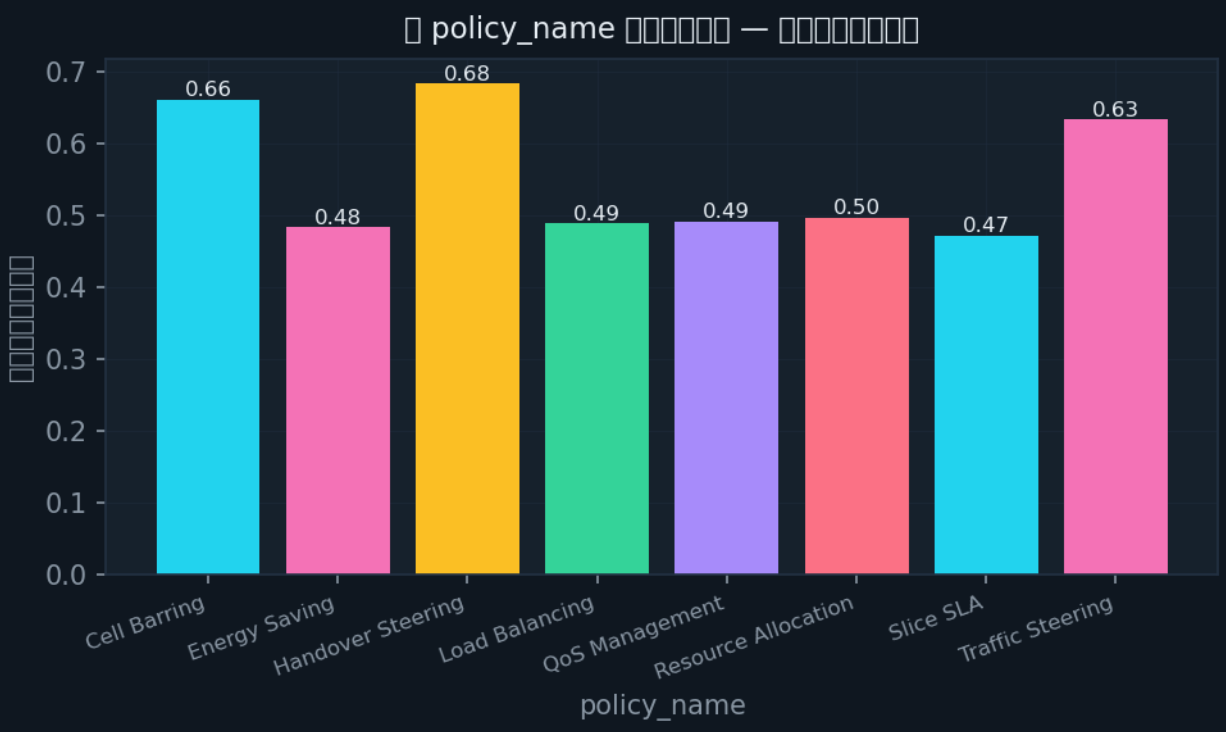
样本按策略名称分为 8 组。考察的是各组的准确率与告警倾向是否一致，是否存在某一组的判定更宽松或更严格。

逐组比较，表现最好的是 小区禁止接入（准确率 100.0%），最差的是 流量引导（99.6%），两者相差 0.4 个百分点。这一项达标。

告警频率方面：被告警比例最高的是 切换引导（占其样本的 68.3%），最低的是 切片 SLA（47.1%）。

通用判据：被告警最少的分组至少应达到最多分组的五分之四（0.8）。本次测得 0.69，判定为未达标，其背后的策略配比需要再平衡。

在本应触发告警的样本中，各组「实际被检出」比例的最大差距为 0.00；该值为 0 表示各组获得的检出水平相同。这一项无需处置。



逐组对比

单条数据的泄露风险（隐私性）

本节检查训练过程是否会输出单条测量数据。

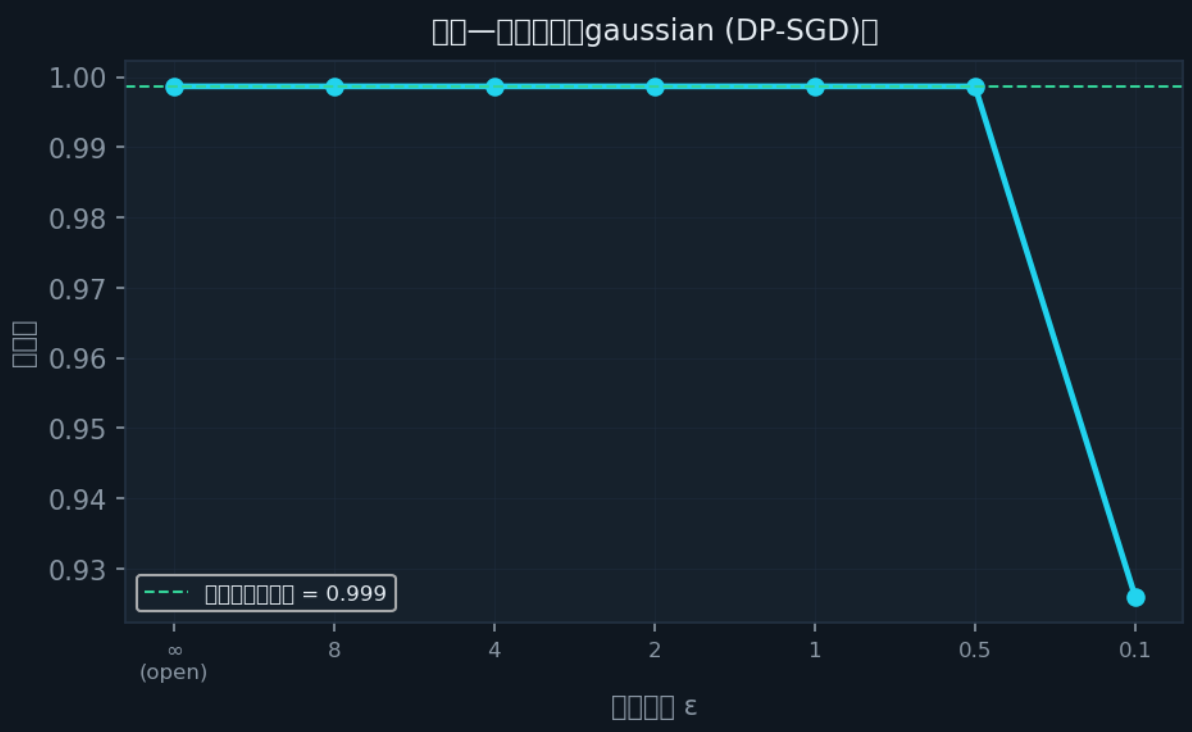
差分隐私的做法是在训练中掺入噪声，使事后无法判定任何单条记录是否被使用；ε 控制噪声强度：ε 越小保护越强，效用代价越大。

在该隐私预算档位上的实测结果：无隐私保护时：99.9%；ε=1：99.9%；ε=0.1：92.6%。

即隐私保护带来的准确率代价约为 0.0 个百分点（收紧至更严格的档位需再付出 7.3）。这一项达标。

成员推断测试：外部人员持有模型副本，并持有一条带真实标签的记录，判断该记录是否用于训练。随机猜测的基线为 0.5；本次得分 0.49，即接近随机猜测，无法据此判定单条记录是否被训练使用。这一项无需处置。

由外部人员自行训练的 4 个影子模型重跑同一测试，群体攻击得分 0.51，似然比攻击得分 0.4904，读数不依赖单一攻击设计。



隐私保护与模型效用之间的取舍

模拟控制室的运行结果

本节数据来自工作台自带的控制室模拟，即该回路的仿真模型，非真实网络。

未采集到状态：生成本报告时模拟会话未在运行。

智能体评测得分

尚未运行 Agent 评测：在 Agent 评测面板运行一次即可填充本节。

数字来源与方法

这些数字的来源：模型先用部分数据训练，之后仅在训练阶段未见过的那部分数据上测试，因此得分衡量的是泛化能力而非记忆。随机种子固定，重跑整次分析会得到相同数值。

本报告全部内容出自同一次运行，因此正文数值与图中数值一致。

同一次运行也可用命令行重放：python -m trustoran --dataset cci_a1sd_binary --quick。

这些数字未证明的部分

- 所用数据为公开研究数据集，非真实网络流量，因此各项得分描述的是本次测试，不代表任何在网基站的实际表现。
- 所用扰动为该类模型的三种已知攻击方式；采用其他手法的攻击者可能得到不同结果。
- 隐私相关数字是本次对噪声精度代价的实测，不构成数据不可还原的合规证明。
- 分组依据是建模选择，非数据本身的属性；更换分组字段，公平性数值会随之变化。
- 智能体在隔离沙箱中受测，其操作未触及真实的计算机、账号或网络。

本模块为个人研究项目，将可信 AI 方法论扩展至 Agent 评测，与任何雇主无关。O-RAN 场景与规范摘要均为公开资料的本人转述。