面向 Open RAN 的可信 AI 分析报告

目标读者：SMO / RIC 运维专用

生成时间:
[cci_a1sd_binary] xgboost — accuracy=1.000
个人研究项目，与任何雇主无关。

目录

- 结论摘要
- 数据集与模型
- 基础性能
- 可解释性
- 鲁棒性
- 公平性
- 隐私性
- O-RAN 控制台快照
- Agent 可信评测
- 方法论与有效性边界

结论摘要

面向 SMO / Non-RT RIC 运维的读数：模型状态、小区边缘需监测的指标，以及应触发 A1 策略复核的阈值。

关键读数

指标	数值
准确率	0.9996
耗时(秒)	5.95
综合	未测量

需关注的指标

- ε=0.3 的对抗扰动下精度损失 32.0 个百分点，应保持 Near-RT RIC 侧限速策略生效。
- 差异影响比为 0.6897，低于 0.8 时应对 A1 策略集做再平衡。
- 建议重点监测的解释性特征：inter_arrival_std, response_time_mean, payload_size_std, payload_size_mean, inter_arrival_cv。

建议处置动作

- 成员推断 AUC 为 0.4946，高于 0.65 表明检测器对训练样本存在记忆，应放宽隐私预算或扩充数据后重训。

数据集与模型

数据集

指标	数值
数据集	cci_a1sd_binary
任务	binary
样本数	24000
特征数	10
类别	Normal, Dos
分组属性	policy_type_id, load_label, operation, policy_name
类别数量	Normal=12000; Dos=12000

数据集内容：A1 接口流量的 Normal 与 DoS 二分类。

模型配置

指标	数值
模型	xgboost
任务	binary
超参	n_estimators=200; max_depth=6; learning_rate=0.1; subsample=0.9; colsample_bytree=0.9; random_state=42
耗时(秒)	5.95

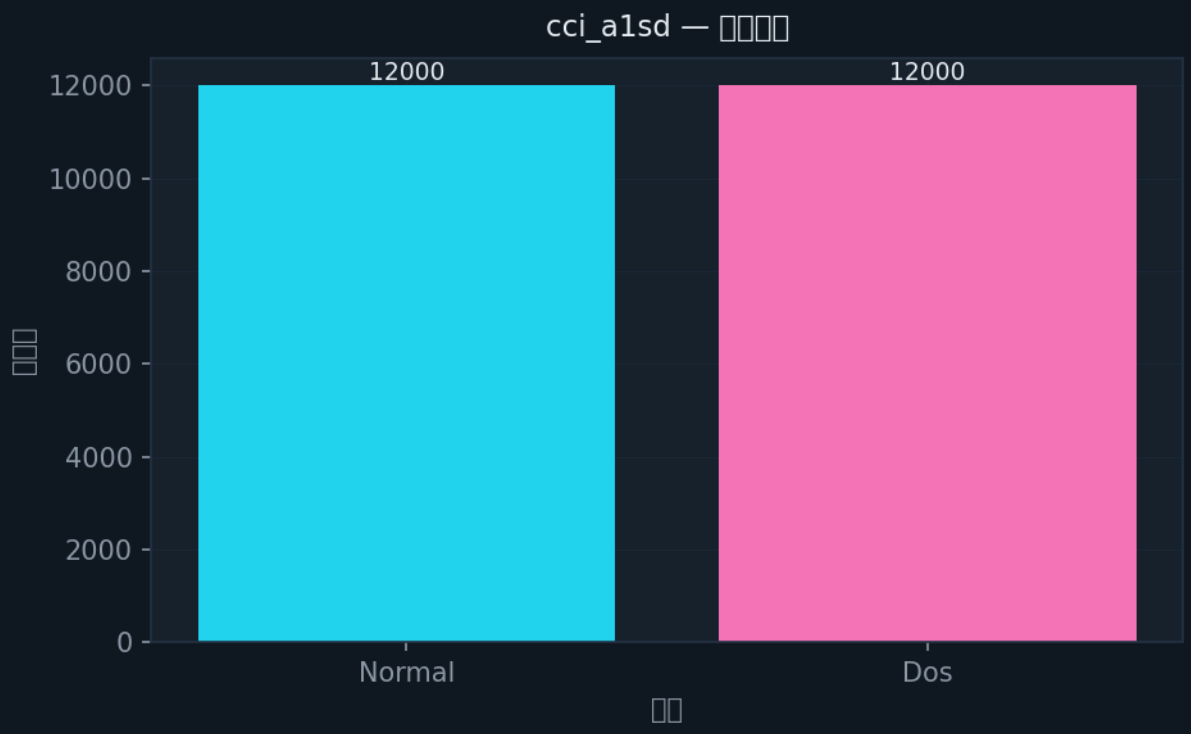
基础性能

留出测试集上的核心指标。

指标	数值
准确率	0.9996
F1(宏)	0.9996

指标	数值
Roc auc	0.9998

图表与各面板显示的内容出自同一次运行。



类别分布

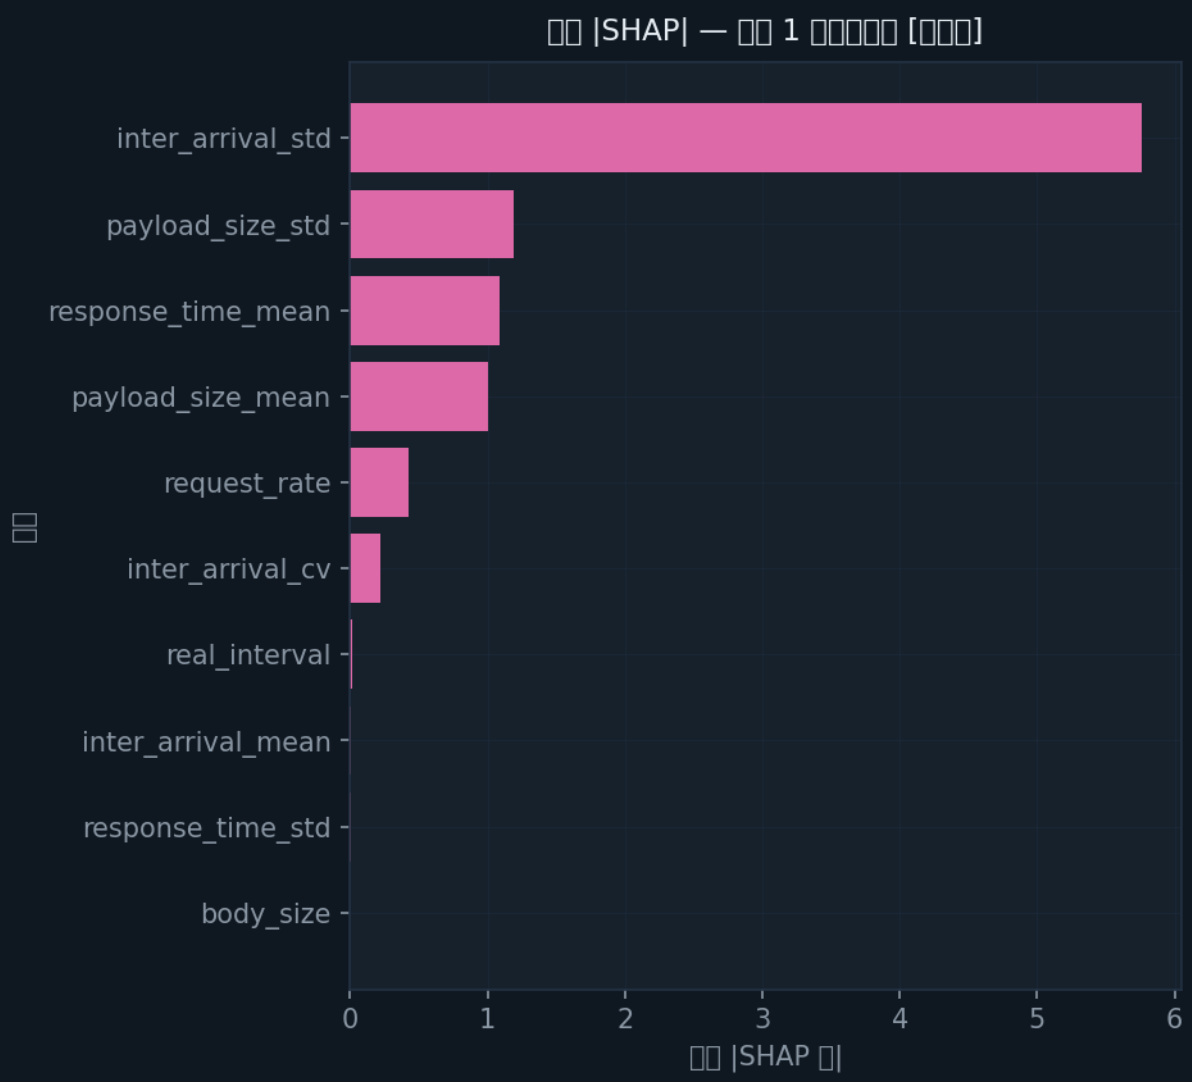


特征直方图

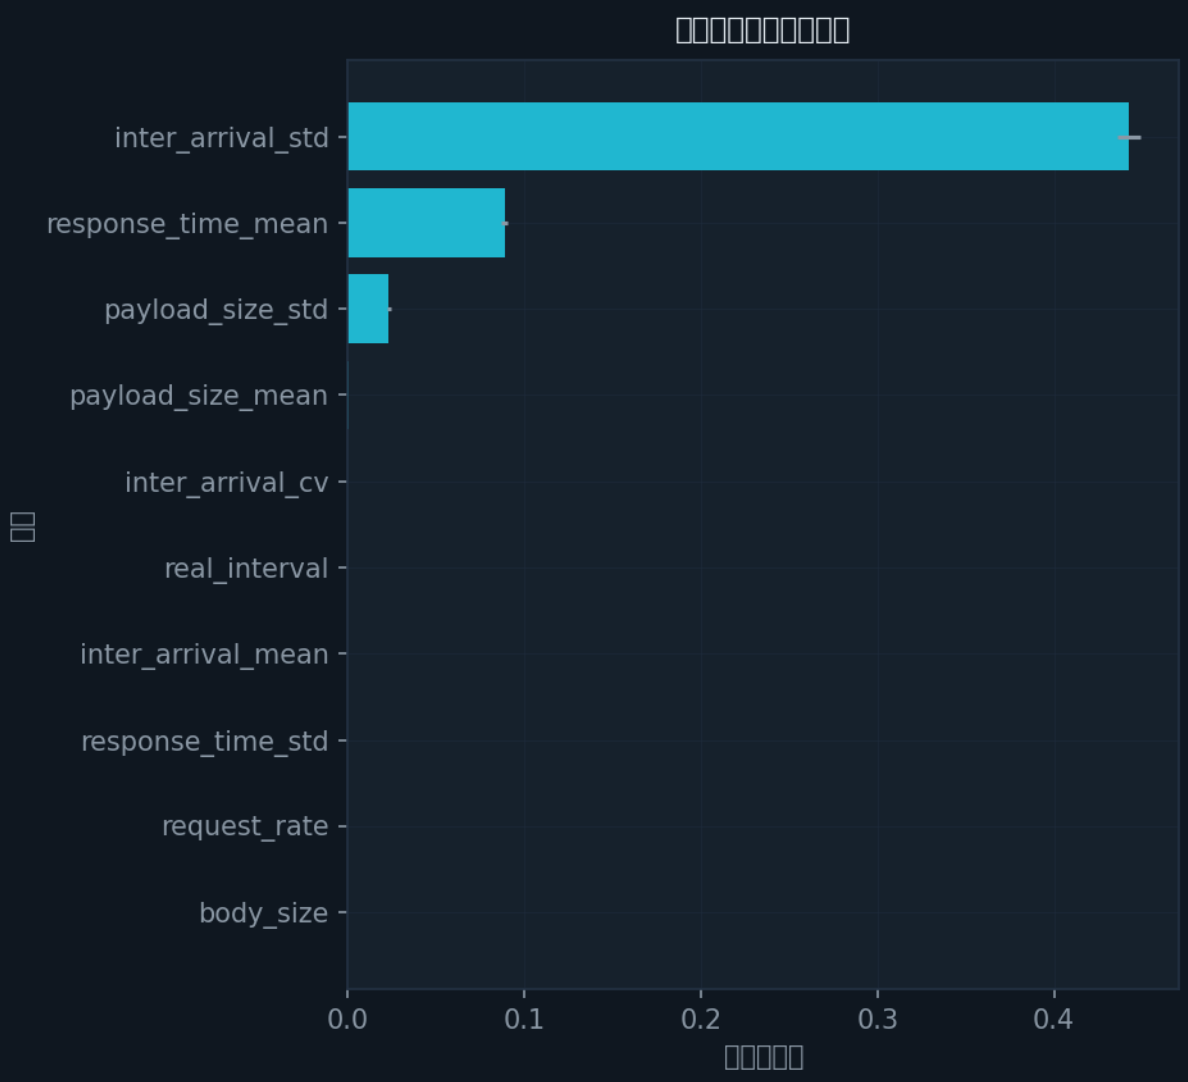
可解释性

归因结果指出哪一个 A1 特征推动了决策，调参与误报申诉均以此为据。

指标	数值
Top 特征	inter_arrival_std, response_time_mean, payload_size_std, payload_size_mean, inter_arrival_cv
目标	类别 1 的对数几率
SHAP Top	inter_arrival_std, payload_size_std, response_time_mean, payload_size_mean, request_rate
方法	置换重要性 + 精确 TreeSHAP（库原生 pred_contribs）+ LIME 式局部代理 + PDP/ICE 曲线
归因估计器	精确解
效率残差(最大)	6.284e-06


□□ |SHAP| — □□ 1 □□□□□□ [□□□]
inter_arrival_std
payload_size_std
response_time_mean
payload_size_mean
request_rate
inter_arrival_cv
real_interval
inter_arrival_mean
response_time_std
body_size
□□
0
1
2
3
4
5
6
□□ |SHAP □|

SHAP 条形

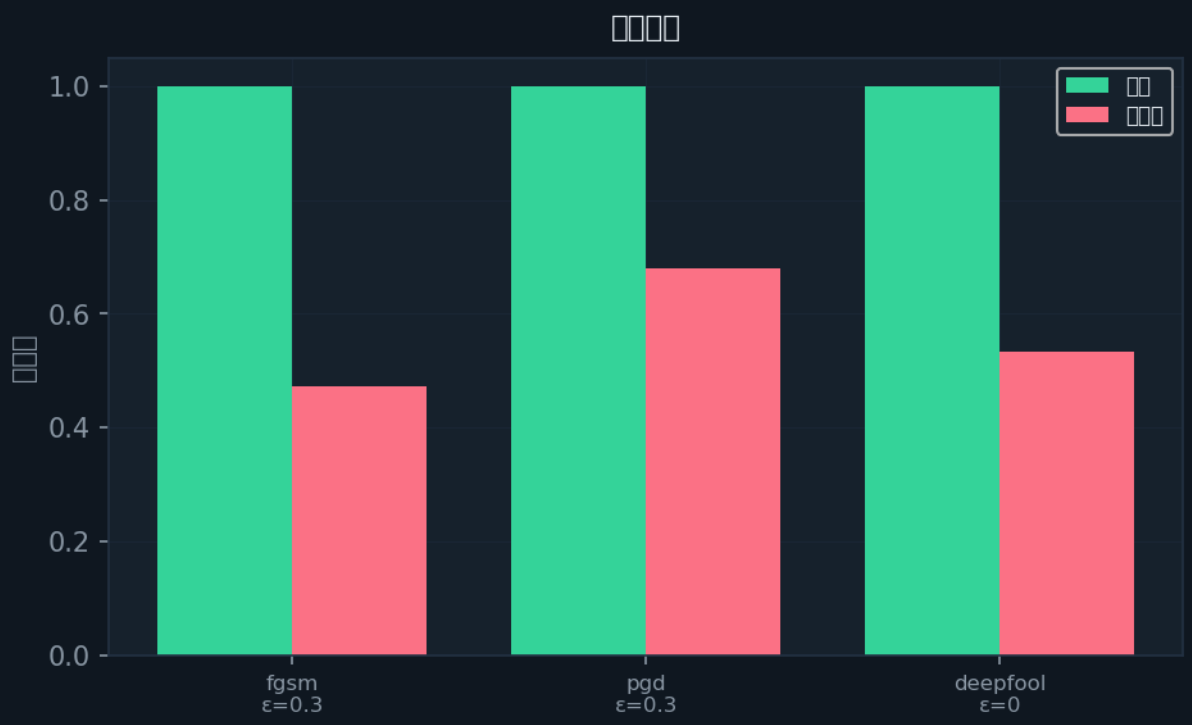


置换重要性

鲁棒性

被篡改流量下的性能退化，这是边缘检测器最现实的失效模式；同时给出对抗训练的缓解效果。

指标	数值
干净准确率	1
FGSM 鲁棒准确率	0.4733
PGD 鲁棒准确率	0.68
DeepFool 鲁棒准确率	0.5333
PGD 攻击成功率	0.32
对抗训练鲁棒准确率@0.6	0.9667



攻击对比



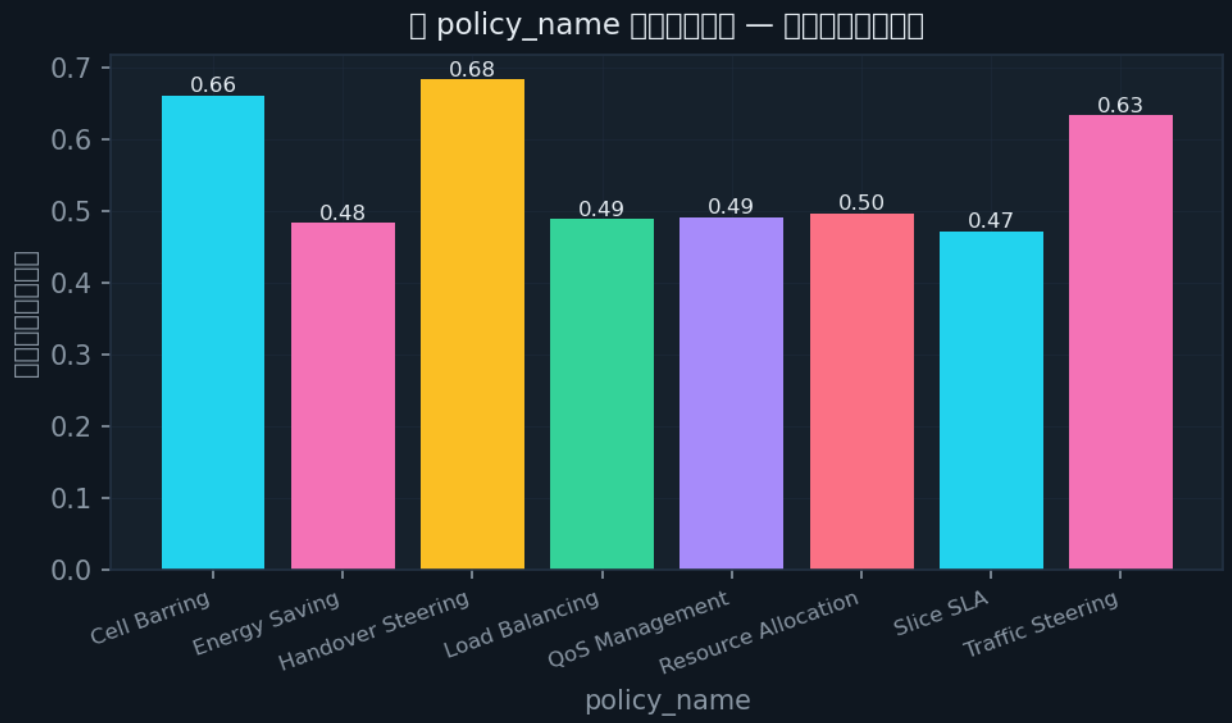
FGSM 鲁棒性

公平性

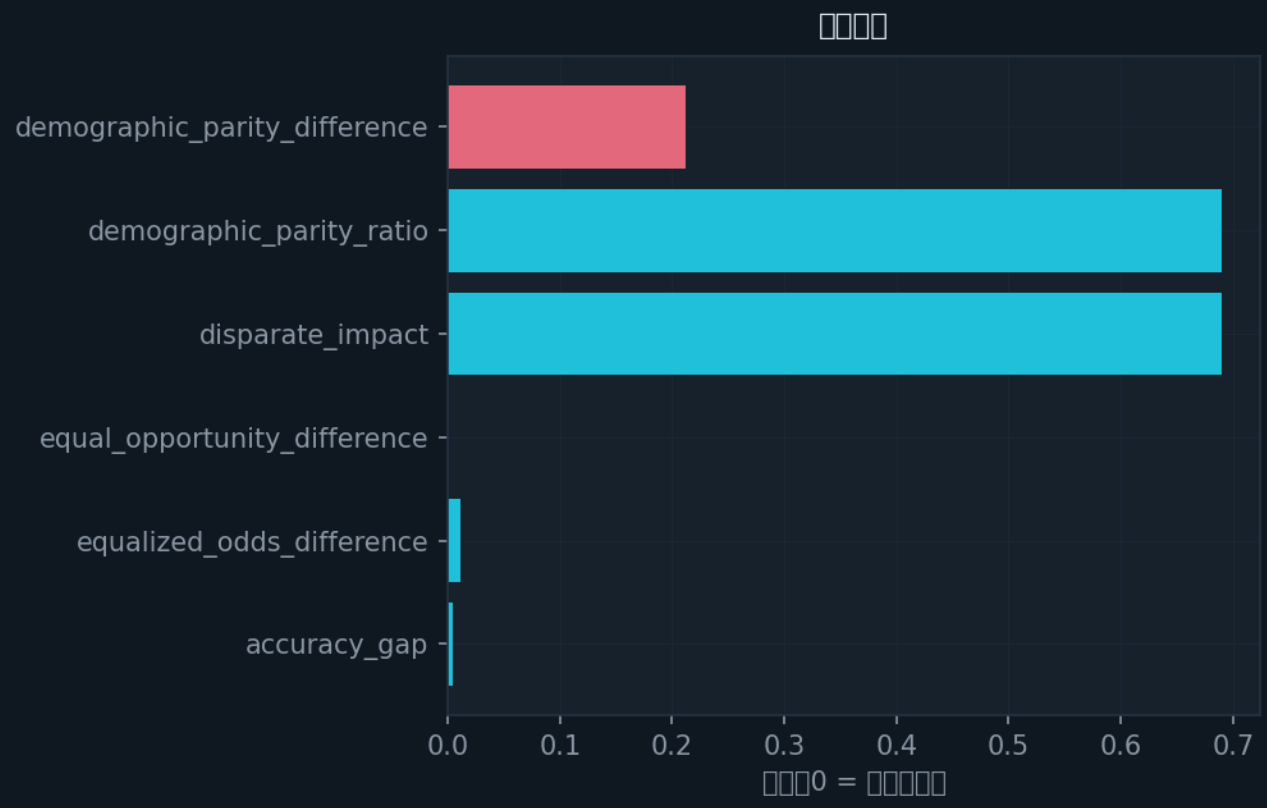
按 策略名称 分组的公平性：同一告警阈值在不同策略类型、Agent 或平台上的行为是否一致。

指标	数值
分组属性	policy_name
组数	8
人口平价差	0.212

指标	数值
人口平价比	0.6897
差异影响	0.6897
机会均等差	0
均等化几率差	0.0116
准确率差	0.0043



分组公平

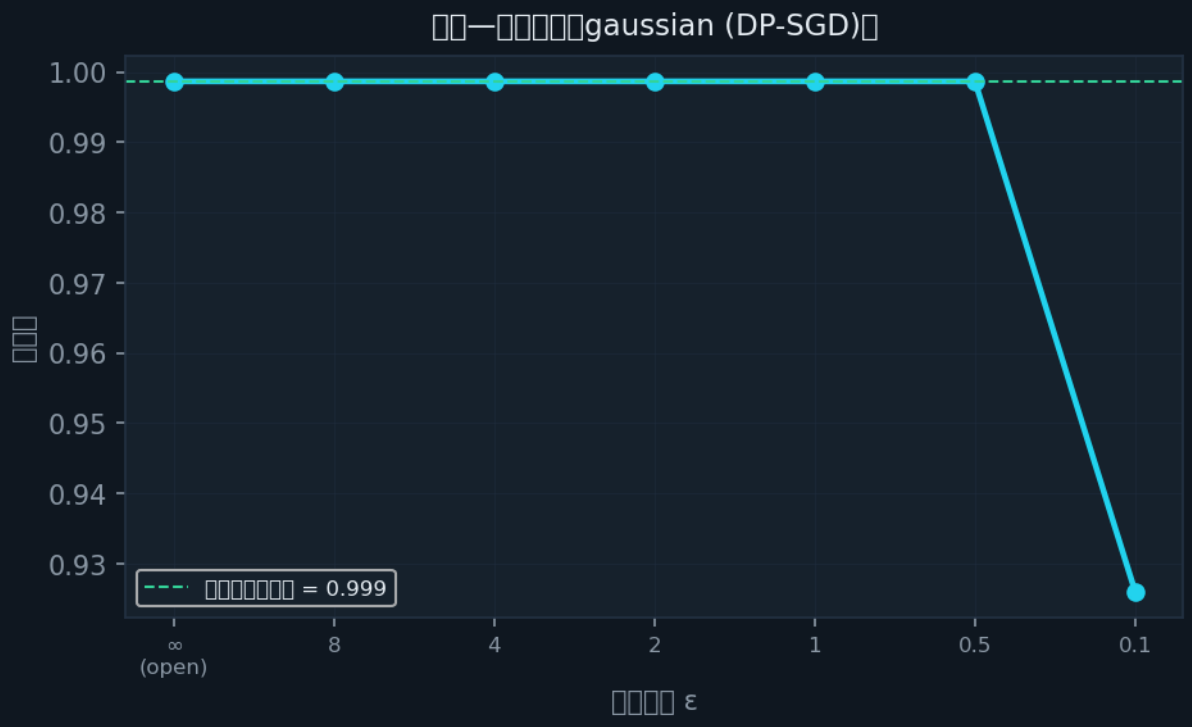


公平指标

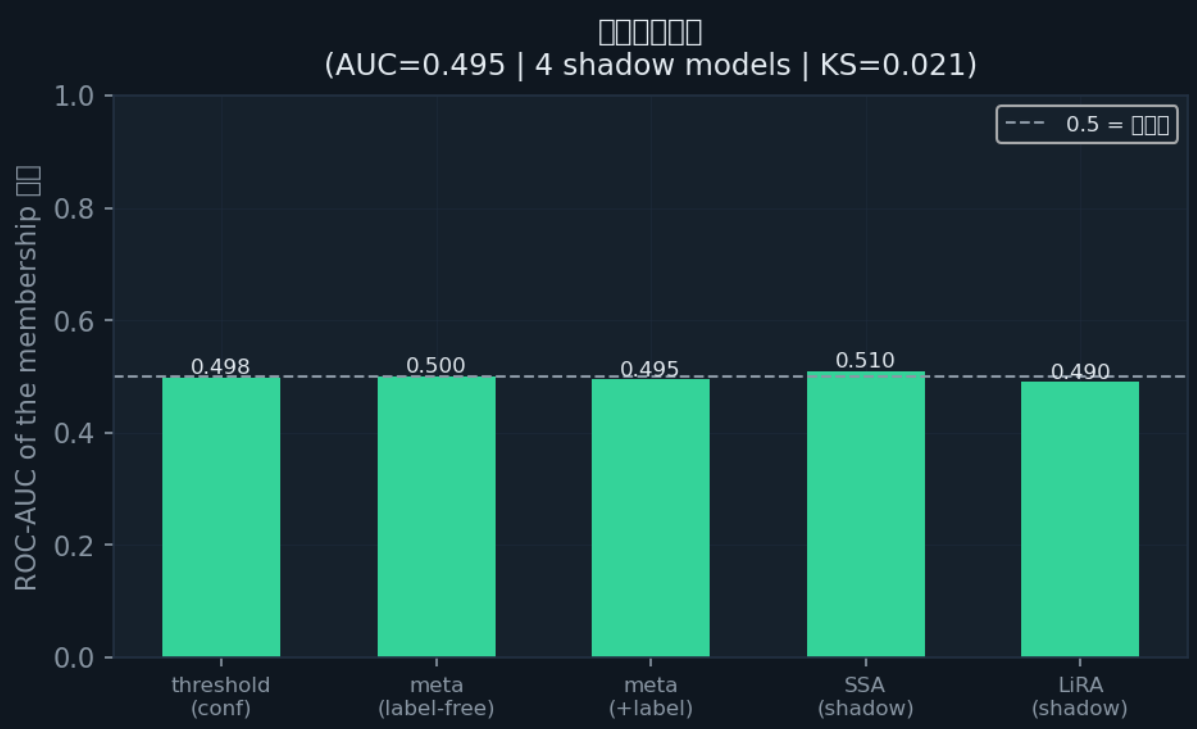
隐私性

隐私预算与联邦：差分隐私需付出的可用性代价，以及边缘 Agent 能否在不上传原始流量的前提下协作学习。

指标	数值
DP 机制	高斯机制（DP-SGD）
无隐私效用	0.9987
效用@ε=1	0.9987
效用@ε=0.1	0.926
成员推断 AUC	0.4946
影子攻击 AUC	0.51
LiRA AUC	0.4904
无标签特征 AUC	0.5
成员/非成员 KS	0.02133
1% 误报命中率	0
影子模型数	4



DP 曲线



成员推断

O-RAN 控制台快照

本次未采集到控制台会话状态。

Agent 可信评测

尚未运行 Agent 评测：在 Agent 评测面板运行一次即可填充本节。

方法论与有效性边界

可复现性

```
python -m trustoran --dataset cci_a1sd_binary --model xgboost --pillars all --quick
python -m trustagent --quick
```

有效性边界

- 数据均为公开研究数据集，非生产网 RAN 遥测数据。
- 攻击采用可微代理梯度，鲁棒性数字刻画的是该类攻击族的效果，不代表任意攻击者。
- 隐私记账沿用本地 DP-SGD 循环中的矩估计方法，未对最终模型给出形式化的 (ε,δ) 证明。
- 公平性分组是在 DATASET_PROFILES 中按数据集预先确定的建模选择，非数据本身的属性。
- Agent 运行环境是带 ACL、预算与确认门的沙箱，未触及任何真实系统或网元。
- Mock 模式下的 Agent 数字只验证评测框架本身，不构成对任何真实模型的测量。
- 规范性表述请直接查阅 O-RAN Alliance 官方规范。

本模块为个人研究项目，将可信 AI 方法论扩展至 Agent 评测，与任何雇主无关。O-RAN 场景与规范摘要均为公开资料的本人转述。